



Uso de redes neuronales para determinar la influencia del estado del pavimento en siniestros viales de la ciudad de Bogotá.

Paula Vanessa Ferro Briceño

Universidad de los Andes
Facultad de Ingeniería, Departamento de Ingeniería Civil y Ambiental
Bogotá, Colombia
2021

Uso de redes neuronales para determinar la influencia del estado del pavimento en siniestros viales de la ciudad de Bogotá.

Paula Vanessa Ferro Briceño

Tesis o trabajo de investigación presentada(o) como requisito para optar al título de:
Magister en Ingeniería Civil

Directora:
Ph.D. Silvia Caro Spinel

Co-asesor:
Mauricio Sánchez-Silva

Universidad de los Andes
Facultad de Ingeniería, Departamento de Ingeniería Civil y Ambiental
Bogotá, Colombia
2021

Agradecimientos

A Silvia Caro Spinel, PhD, maestra, vicedecana y directora de esta investigación por toda su confianza. A Luis Fernando Sabogal, estudiante de pregrado de Ingeniería Civil, por su ayuda continua. A Carlo Di Francescantonio, Ingeniero Civil y Matemático por su paciencia al enseñarme sobre inteligencia artificial. A la Secretaría Distrital de Movilidad por inspirarme a salvar vidas, y sobre todo, a mi familia, a Nico y a Sonia por nunca desfallecer ante mis deseos y aplaudir mis esfuerzos.

Resumen

La siniestralidad vial debe ser vista como un problema de salud pública, y todo esfuerzo por disminuir las víctimas debe ser considerado como fundamental. Dentro de este contexto, esta investigación tiene como objetivo analizar la influencia del estado de la malla vial, diagnosticada en por el Instituto de Desarrollo Urbano (IDU) de la ciudad de Bogotá el año 2016, en los siniestros viales reportados desde el año 2007 por la policía de tránsito a la Secretaría Distrital de Movilidad (SDM). Este análisis se realiza a partir de la construcción de una red neuronal multicapa conectada, donde los datos de entrada fueron obtenidos de una base de datos que relaciona siniestros viales con variables propias de la condición del pavimento y el resultado del aprendizaje es la predicción de la probabilidad de que un siniestro suceda y su gravedad sea “solo daños”, “con heridos”, o “con muertos”. Después de un análisis de sensibilidad en las variables asociadas a la condición del pavimento, se encontró que no representa un factor determinante en el resultado de la gravedad de un siniestro fatal, pero sí tiene incidencia en siniestros de solo daños y heridos. Se concluye también que la velocidad sí se considera un factor de riesgo en la gravedad del siniestro y se propone incluirla en investigaciones posteriores que se deseen realizar haciendo uso de redes neuronales.

Palabras clave: Siniestralidad vial, seguridad vial, estado del pavimento, redes neuronales, inteligencia artificial.

Abstract

Road accidents must be seen as a public health problem. Consequently, any effort to reduce the number of victims is fundamental. This research analyzes the influence of the state of the road network (diagnosed in 2016 by the IDU of the city of Bogotá) in the type of road accidents reported since 2007 by the traffic police to the Secretary of Mobility of the city. This analysis is carried out from the construction of a fully connected multilayer neural network. The input data were obtained from a database that included the location of road accidents and the characteristics of the condition of the pavement. The output is the prediction of the probability of an accident to happen and its severity, classified as “only damage”, “injuries”, or “deaths”. After a sensitivity analysis on the variables associated with the condition of the pavement, it was found that PCI and pavement surface does not represent a key factor in the result of the severity of a fatal accident, but it does have an impact on accidents that resulted in damage and injuries. It is also concluded that vehicle speed is a risk factor in the severity of the accident. It is proposed to include this variable in subsequent investigations using neural networks.

Keywords: road safety, road accident, pavement condition, neural network.

Contenido

	Pág.
1. Introducción	1
2. Objetivos.....	3
2.1 Objetivo general	3
2.2 Objetivos específicos	3
2.3 Objetivo a largo plazo	3
3. Marco teórico	5
3.1 Accidentalidad vial.....	5
3.2 Siniestralidad vial	5
3.2.1 Accidente de tránsito vs. siniestro vial	6
3.3 Gravedad de un siniestro vial.....	6
3.3.1 Fallecido por siniestro vial.....	7
3.3.2 Lesionado por siniestro vial.....	7
3.3.3 Siniestro solo daños	7
3.4 Condición del pavimento.....	7
3.4.1 Índice de Condición del Pavimento (PCI)	7
3.5 Estado Superficial	8
4. Estado del Conocimiento.....	10
4.1 Gravedad en siniestros viales	11
4.2 Variables asociadas a un siniestro vial	11
4.3 Modelación de siniestros viales	12
4.4 Tipos de redes neuronales.....	12
5. Problemática	15
6. Metodología.....	16
7. Desarrollo	19
7.1 Bases de datos.....	19
7.2 Análisis base de datos	22
7.3 Construcción red neuronal	25
7.4 Construcción Regresión Logística	28
7.5 Análisis de sensibilidad	30
8. Conclusiones y recomendaciones.....	34
8.1 Conclusiones.....	34
8.2 Recomendaciones.....	35
9. Bibliografía	51

Lista de figuras

	Pág.
Figura 1. Metodología de investigación.	17
Figura 2. Clasificación Estado según PCI - IDU.	21
Figura 3. Mapa georreferenciado - Estado del Pavimento.....	22
Figura 4. Mapa georreferenciado de siniestros viales	23
Figura 5. Correlación Siniestralidad vial vs estado de la malla vial.....	24
Figura 6. Veracidad NN – Python.....	27
Figura 7. Veracidad de la regresión logística.	29
Figura 8. Visualización del análisis de sensibilidad – PCI	31
Figura 9. Visualización del análisis de sensibilidad – superficie	32

Lista de tablas

Pág.

Tabla 1. Clasificación PCI - Personalizada según IDU 2020.	8
Tabla 2. Variables del IPAT.....	20
Tabla 3. Variables IDU Estado de la Malla Vial	21
Tabla 4. Matriz de confusión - red neuronal	27
Tabla 5. Matriz de confusión - Regresión Logística.....	28
Tabla 6. Análisis de sensibilidad - PCI	30
Tabla 7. Análisis de sensibilidad - variación superficie	32

1.Introducción

La siniestralidad vial en Bogotá es una problemática de salud pública mundial que cada año ocasiona la muerte de, aproximadamente, 1.35 millones de personas en todo el mundo, siendo una de las principales causas de muerte en todos los grupos etarios, y la primera entre personas que tienen entre 15 y 29 años, tal como lo ha señalado la Organización Mundial de la Salud (WHO, 2017). Así mismo, la siniestralidad vial causa más fatalidades que enfermedades como el EPOC (enfermedad pulmonar obstructiva crónica), el cáncer de cuello uterino, la diabetes y el cáncer de mama. Además, supera el número de víctimas mortales por conflicto armado, suicidio y muertes accidentales en la ciudad (Secretaría Distrital de Movilidad, 2018).

Las instituciones que están relacionadas con la siniestralidad vial en la ciudad han desarrollado distintas estrategias para atacar esta problemática a través de campañas en medios de comunicación, compra y contratación de herramientas técnicas como cámaras y sensores, y estudios con distintos actores nacionales e internacionales para determinar las causas más probables de los accidentes y su posible tratamiento. Asimismo, han conformado dentro de las instituciones equipos destinados a la investigación y priorización de la seguridad vial, tal y como lo es la Oficina de Seguridad vial de la Secretaría Distrital de Movilidad (SDM), desarrollo de programas de mejoramiento de sectores que se consideraban problemáticos, como el estado del pavimento y las calles en su complejidad, como las brigadas de Alto impacto, Baja Inversión de la Unidad de Mantenimiento Vial (UMV) o la reestructuración organizacional del Instituto de Desarrollo Urbano (IDU).

A pesar de la dimensión que tiene la problemática de la siniestralidad vial en la ciudad de Bogotá, no existen muchos estudios sistemáticos que den cuenta de los múltiples factores que inciden en la ocurrencia de eventos fatales en el tránsito capitalino. Los estudios que realizan de forma permanente instituciones como el Instituto Nacional de Medicina Legal y Ciencias Forenses y la Agencia Nacional de Seguridad Vial se han dedicado fundamentalmente a un tratamiento

estadístico del fenómeno, quedando pendiente un análisis de las razones que subyacen en la ocurrencia de un accidente de tránsito. Desde el ámbito académico, los estudios realizados están generalmente centrados en aspectos puntuales de la problemática, pero no muchos han explorado la correlación que existe entre la condición del pavimento y la gravedad del siniestro. De hecho, aun menos trabajos en este tema han hecho uso de herramientas novedosas como redes neuronales e inteligencia artificial, la cual supera algunos de los retos de modelos estadísticos y probabilísticos y ejerce un aprendizaje basado en los datos reales de la ciudad de Bogotá. A partir de la construcción de una red neural, este trabajo de tesis busca explorar y aportar nueva información sobre posibles relaciones entre la accidentalidad vial y el estado y calidad de la infraestructura vial de la ciudad de Bogotá.

2. Objetivos

2.1 Objetivo general

Hacer uso de redes neuronales para predecir la gravedad, clasificada como “con muertos”, “con heridos”, o “solo daños” de un siniestro vial en función del estado de la malla vial de la ciudad de Bogotá.

2.2 Objetivos específicos

- Correlacionar la base de datos de siniestralidad vial de la ciudad de Bogotá, diligenciada desde la Policía de Tránsito y manipulada por la Secretaría Distrital de Movilidad con la base de datos de estado de malla vial realizada por el Instituto de Desarrollo Urbano para la malla vial y urbana.
- Construir una red neuronal que aprenda sobre la correlación de las bases mencionadas anteriormente, y prediga la gravedad del siniestro: fatal, con heridos, o solo daños.
- Realizar un análisis variando la condición del pavimento, caracterizada bajo el PCI, para entender cómo se comporta la gravedad de los siniestros viales.

2.3 Objetivo a largo plazo

Los resultados de este trabajo se podrían incluir como una variable adicional dentro de los planes de gestión de pavimentos de la ciudad de Bogotá, con el fin de aunar esfuerzos en pro de la visión cero y la disminución de muertes y cantidad de siniestros en la ciudad de Bogotá, y en Colombia.

3. Marco teórico

3.1 Accidentalidad vial

El fenómeno de la accidentalidad vial hace referencia a los hechos que toman lugar en la vía pública y que tienen que ver con vehículos de cualquier tipo. Se entiende también como el conflicto entre actores viales que transitan libremente en el espacio ya sea urbano o rural. Este fenómeno involucra ya sea automóviles, vehículos de carga, autobuses, bicicletas, y/o peatones. Cada día, alrededor de 3500 personas fallecen en las vías. Decenas de millones de personas sufren heridas o discapacidades cada año por esta misma causa (Secretaría de Movilidad, 2018).

3.2 Siniestralidad vial

Se refiere a cualquier suceso que involucre al menos un vehículo en movimiento que tenga lugar en vía pública o privada a la que la población tenga derecho de acceso y que como consecuencia causa daños a personas, animales o bienes involucrados en él. Las colisiones múltiples se contabilizan como un solo siniestro vial si las colisiones se suceden en cadena (Anuario Nacional de Siniestralidad Vial, 2019). Las siguientes situaciones hacen parte de los eventos registrados como siniestralidad vial: las colisiones entre vehículos; entre vehículos y peatones; entre vehículos y animales u obstáculos fijos; con vehículos ferroviarios en la vía; además volcamientos; incendios; caídas de pasajeros u ocupantes. Se excluyen de esta clasificación, los suicidios o intentos de suicidios en vías, ya que son actos deliberados de infligirse lesiones mortales. Sin embargo, si un suicidio o un intento de suicidio causan lesiones a otro usuario este se considera un siniestro vial. También se excluyen los actos terroristas y los incidentes relacionados con transporte acuático.

3.2.1 Accidente de tránsito vs. siniestro vial

La discusión sobre el uso del término siniestro como sustantivo que reemplaza al término

accidente para denominar los sucesos que involucran vehículos en movimiento y que generan algún tipo de daño, es el primer punto de encuentro para alinear los esfuerzos institucionales y discutir un hecho que es prevenible y predecible y que afecta la salud de miles de personas en Colombia. Es en este punto que cobran sentido las discusiones que han tenido lugar en distintos momentos y contextos para transformar el lenguaje y unificar el discurso, inicialmente, desde el nivel comunicacional, bajo las nuevas visiones existentes sobre seguridad vial y su impacto en la salud. Asumir la siniestralidad vial-accidentalidad vial como un problema de salud pública y bajo un nuevo enfoque (Visión Cero y Sistema Seguro), obliga a dejar de lado el uso del término accidente, entendida como algo fortuito, inesperado y sin responsabilidad de las partes, para ser reemplazada por la palabra siniestro, y de esta manera reforzar la idea de que los eventos en las vías son prevenibles, tal y como lo argumentan varias instituciones y organismos como la Organización Mundial de la Salud (OMS), el International Transport Forum (ITF), el Observatorio Iberoamericano de Seguridad Vial (OISV) e iniciativas como Visión Cero.

Dos argumentos sustentan este cambio. El primero relacionado con la discusión alrededor de las nuevas visiones que hay sobre la siniestralidad vial y el segundo correspondiendo al campo semántico de los términos usados. El diccionario de la Real Academia Española define siniestro como: un ‘suceso que produce un daño o una pérdida material considerables’, y accidente lo define como: un ‘Suceso eventual que altera el orden regular de las cosas’ o ‘suceso eventual o acción de que resulta daño involuntario para las personas o las cosas’ (DRAE, 2019). La diferencia sustancial entre los términos radica en la ‘eventualidad’ de que suceda o no. Si es eventual es accidente y si no, es siniestro. Tal eventualidad no es otra cosa que el carácter de imprevisible o fortuito que está asociada con la ocurrencia o no del suceso.

3.3 Gravedad de un siniestro vial

Los siniestros viales se pueden clasificar de distintas formas; sin embargo, la más sensata con el objetivo de analizar el comportamiento y en aras a disminuir los datos, es por la gravedad. Esta se divide en 3: siniestro con fallecidos, siniestro con heridos, y siniestro solo daños. A continuación se presenta la definición de cada uno (Agencia Nacional de Seguridad Vial, 2020):

3.3.1 Fallecido por siniestro vial

Cualquier persona que presenta desaparición permanente de todo signo vital como consecuencia de la ocurrencia de un siniestro vial. No se tienen en cuenta los casos en los que la autoridad competente declara que la causa de la muerte ha sido un suicidio.

3.3.2 Lesionado por siniestro vial

Cualquier persona que haya sufrido daño físico o mental y que requiera atención en salud como consecuencia de la ocurrencia de un siniestro vial. También se tienen en cuenta lesionados por siniestro vial que cumplan con al menos uno de los siguientes criterios:

- Que tenga al menos una hospitalización por un periodo de 24 horas o más, y que no corresponda únicamente a observación.
- Que tenga una incapacidad laboral y ocupacional mayor o igual a tres días (72 horas).
- Que presente algún tipo de discapacidad directamente relacionada con la lesión resultante del siniestro vial.

3.3.3 Siniestro solo daños

Cualquier siniestro que no se clasifique en fallecido o lesionado, determinado por la autoridad competente, en el caso de la ciudad de Bogotá, la Policía de Tránsito. Generalmente, en esta categoría se encuentran los siniestros en donde se generan únicamente daños materiales y no se requiere atención médica para ninguna de las partes involucradas.

3.4 Condición del pavimento

3.4.1 Índice de Condición del Pavimento (PCI)

Para efectos de evaluación de pavimentos, y de acuerdo con lo definido en la Norma ASTM D 6433 – 18, el Índice de Condición del Pavimento (PCI) es un indicador del estado de condición superficial de un pavimento con superficie flexible, rígida o articulada, el cual se determina a partir de un inventario de fallas, teniendo en cuenta para su cálculo, el tipo, extensión y severidad de las mismas. Este índice numérico varía desde cero (0), para un pavimento fallado o en mal

estado, hasta cien (100) para un pavimento en perfecto estado. El cálculo del PCI se fundamenta en los resultados de un inventario visual de la condición del pavimento en el cual se establecen CLASE, SEVERIDAD y CANTIDAD de cada daño presenta. El PCI se desarrolló para obtener un índice de la integridad estructural del pavimento y de la condición operacional de la superficie. La información de los daños obtenida como parte del inventario ofrece una percepción clara de las causas de los daños y su relación con las cargas o con el clima. En la ciudad de Bogotá, la clasificación es la siguiente:

Tabla 1. Clasificación PCI - Personalizada según IDU 2020.

Clasificación PCI – Personalizada IDU	
	MAL ESTADO $0 \geq \text{PCI} \leq 55$
	REGULAR ESTADO $55 > \text{PCI} < 90$
	BUEN ESTADO $90 \geq \text{PCI} \leq 100$

3.5 Estado Superficial

Para la ciudad de Bogotá, corresponde a un indicador que permite dar el estado del tipo de superficie de la calzada mediante la realización de una evaluación superficial teniendo en cuenta el inventario de fallas del pavimento. El estado de la malla vial de la ciudad (urbana y rural), se calcula a partir de la información contenida en el Sistema de Información Geográfica del IDU, SIGIDU de la siguiente manera (Instituto de Desarrollo Urbano, 2019):

a) Malla vial Urbana: Para los pavimentos de la malla vial urbana con superficie flexible, rígida o articulada (adoquín), el estado se determina a partir del Índice de Condición del Pavimento (PCI), establecido en las normas ASTM-D-6433-18 y ASTM-E-2840-15, a partir de los rangos de la Clasificación propios del IDU y que responden al comportamiento de los pavimentos para la ciudad de Bogotá. Para las superficies en afirmado y tierra, el estado se reporta en la clasificación “MALO”

b) Malla vial Rural: Para los pavimentos de la malla vial rural con superficie flexible, rígida o articulada (adoquín), el estado se determina de la misma manera como se realiza para la malla vial urbana. Para las vías con superficies en afirmado y tierra, el estado se determina a partir del Índice de Condición de Vías Sin Superficie (URCI), establecido en el Manual Técnico TM-5-626, a partir de los rangos de la Clasificación propios del IDU y que responden al comportamiento de los pavimentos para la ciudad de Bogotá."

4.Estado del Conocimiento

En promedio, la siniestralidad vial cobra 1.35 millones de vidas a nivel mundial cada año, es por esto por lo que debe ser tratada como un problema de salud pública según la OMS (2015). Inicialmente, los investigadores de esta disciplina han reducido la comprensión de este tema a modelos probabilísticos con variables puntuales. Sin embargo, al hacer uso de nuevas tecnologías, como la inteligencia artificial y las redes neuronales, se encuentra un resultado más detallado y verídico.

Esta investigación se centra en la siniestralidad vial, e intenta explicarla, o al menos relacionarla, desde las condiciones del pavimento por medio de redes neuronales. Los primeros esfuerzos en este tema se identifican desde el año 2004, en donde se empiezan a esbozar bases para lo que se conoce como *Visión Cero* en Suiza, se sigue recorriendo hacia China y Japón donde se empezaron a desarrollar modelos probabilísticos sobre la siniestralidad vial, para luego pasar a modelos en inteligencia artificial, más específicamente, en redes neuronales, no sin antes entrar en los estudios realizados por la Federal Highway Association en Estados Unidos sobre la calificación de los pavimentos, el estudio de su condición y las variables que lo afectan considerablemente .

En este estudio se trabajará a partir de los esfuerzos existentes y de la información disponible en la ciudad de Bogotá para, a partir del estudio de las condiciones del pavimento y de otras variables explicativas, explorar la existencia de correlaciones entre la gravedad de los siniestros viales y el estado de las vías y se evaluará la posibilidad de modificar los sistemas de gestión de pavimentos para disminuir el número de siniestros viales. Es así como se espera entender el contexto internacional, las investigaciones previamente realizadas, para después aplicarlos al contexto de la ciudad de Bogotá.

4.1 Gravedad en siniestros viales

Un siniestro vial, generalmente, se clasifica en categorías basada su gravedad: leve, moderado o grave. Leve corresponde a un siniestro en donde solo hubo daños materiales, moderado significa que existió un herido o lesionado a causa del siniestro. En esta categoría se entra en un dilema, ya que, si este herido es llevado al hospital, se deberá tener un seguimiento mandatorio para saber si sale con vida o no del hospital dándole paso a la siguiente tipificación, grave. Un siniestro grave, o fatal, indica la muerte de algún actor involucrado ya sea en el momento del choque, como tras una intervención hospitalaria. Según el análisis realizado por William Arias y Saieth Chavez (2017) sobre la publicación de la Agencia Nacional de Seguridad Vial en Colombia, cada 2 minutos y medio ocurre un accidente de tránsito, cada 10 minutos hay un herido y cada hora hay un herido fatal, debido a las bajas garantías y pobres condiciones de la infraestructura vial del país.

4.2 Variables asociadas a un siniestro vial

En orden de prevenir y disminuir la cantidad de siniestros viales, se ha hecho un estudio sobre las posibles variables que podrían explicar la causalidad de estos hechos. El exceso de velocidad es la principal causa en la siniestralidad vial. El 89% de los siniestros ocurren por falla humana, el 11% restante, ocurren por problemas mecánicos, factores climáticos y defectos en la vía, entre otros (Arias, 2006). Este análisis de sensibilidad de variables es sumamente importante para modelar el problema, ya que se deberán cuantificar, normalizar y en general, darle tratamiento a estas variables para que se ajusten a un modelo que replique las condiciones para entender qué se puede cambiar para que no ocurra.

Estudios más recientes realizados en el 2018 por investigadores de China, confirman que uno de los factores más influyentes es la conducta humana y, de igual forma, las condiciones mecánicas del vehículo, sin embargo, también hallan cierta significancia en variables que no se habían considerado previamente, tales como la edad del conductor y la hora del día. (Li, Ma, Zhu, Zeng, & Wang, 2018)

4.3 Modelación de siniestros viales

El modelo de regresión logística y el modelo de elección han sido las técnicas más comúnmente aplicadas en el análisis de lesiones de tránsito. Sin embargo, la mayoría de los modelos de regresión tienen sus propios supuestos y relaciones subyacentes predefinidas entre variables dependientes e independientes. Si estos supuestos no se cumplen, el modelo podría dar lugar a estimaciones erróneas de la probabilidad de la gravedad del siniestro. Es por esto, que desde el 2006, Chang y Wang iniciaron pruebas con modelos basados en inteligencia artificial, llamado CART (Classification and regression tree). Este es un modelo no paramétrico, sin ninguna relación predeterminada entre las variables, que tiene la capacidad de buscar sus mejores variables predictoras por sí mismo, “aprendiendo” de casos reales (Chang & Wang, 2006).

Posteriormente, el instituto de transporte Texas A&M comparó el desempeño de distintos modelos de redes neuronales, entre estos el modelo de red neuronal de retro propagación (Back Propagation Neural Network) y el modelo de redes neuronales bayesianas (Bayesian Neural Networks), siendo este último más eficiente debido a la reducción de tiempo de convergencia relacionada con el sobreajuste de datos (Xie, Lord, & Zhang, 2007).

Modelaciones aún más recientes de siniestros viales demuestran la correlación existente entre condiciones defectuosas de la estructura de pavimento y los accidentes graves. Sin embargo, no se puede afirmar que esta relación sea lineal, teniendo en cuenta que las condiciones muy defectuosas de la estructura de pavimento presentan una mayor correlación con los accidentes de tipo leve. Para entender con mayor detalle este fenómeno, se propone la incorporación de una nueva variable como lo es la velocidad de tráfico, la cual puede ser un factor determinante en el momento de evaluar la gravedad del accidente (Li, Liu, & Ding, 2013).

4.4 Tipos de redes neuronales

Las redes neuronales son una rama de la inteligencia artificial, la cual tiene por objetivo analizar el funcionamiento del cerebro humano para replicar su forma de analizar y procesar datos. Las redes neuronales se pueden clasificar de diferentes maneras. La primera, es según la topología de la red: La red neuronal monocapa, es decir, una sola capa de procesamiento. La segunda es la red neuronal multicapa, la cual hace uso de varias capas de neuronas para aprender y probar los datos ingresados. La tercera es la red neuronal convolucional, la cual usa varias capas de

neuronas, pero a diferencia de la multicapa, no todas las capas están conectadas. La cuarta, es la red neuronal recurrente, la cual no tiene una estructura de capas, sino que permiten conexiones arbitrarias entre las neuronas. Por último, las redes de base radial, las cuales calculan la salida de la función en función de la distancia a un punto denominado centro. La siguiente forma de clasificarlas es por el tipo de aprendizaje que tiene la propia red, puede ser supervisado, por corrección de error, aprendizaje estocástico o no supervisado.

De acuerdo con lo hallado por Zeng & Huang (2014), los algoritmos con redes neuronales son muy superiores a los modelos probabilísticos para la predicción de la gravedad de las lesiones en accidentes de tránsito, lo anterior debido a que múltiples estudios muestran que algunas variables no poseen relaciones lineales. Es así como se logra evidenciar el atraso en el uso de modelos probabilísticos para predecir la gravedad de un siniestro vial, y se muestra la importancia de avanzar a redes neuronales, en todos sus tipos, para modelar estos fenómenos y conseguir unas variables explicativas veraces en las que se pueda intervenir y así, disminuir la cantidad de siniestros viales.

5. Problemática

En un estudio realizado por la Agencia de Cooperación Internacional Japonesa JICA (1998) para la ciudad de Bogotá, se evidencian algunos problemas de la ciudad que están relacionados con la siniestralidad vial, tales como:

- Falta de planeación para el desarrollo y crecimiento de la ciudad
- Problemas asociados al transporte público: falta de integración
- Incremento importante de la tasa de crecimiento de la población debido a la migración rural e internacional acelerada por factores como empleo, desplazamiento forzado por la violencia, servicios públicos inadecuados, etc.
- Falta de infraestructura segura y resiliente
- Falta de adecuación de infraestructura peatonal y accesible.
- Escasa señalización, mal estado de la señalética y falta de demarcación en algunas zonas de la ciudad
- Estacionamiento inadecuado sobre vía o en andenes
- **Deterioro de la malla vial**
- Falta de educación de conductores y peatones en aspectos relacionados con las normas de tránsito
- Elevado grado de motorización
- Alta contaminación ambiental, sumada a problemas de tráfico y que repercuten en el comportamiento y en el estado salud de diferentes actores viales
- Prevalencia de puntos y corredores críticos en siniestralidad
- Malos hábitos de conducción, como pasar por alto normas y señales de tránsito
- Sistema de licencias de conducción es inadecuado

Los siniestros de transporte son la segunda causa más importante de muertes violentas en Colombia. Es por esta razón que se encuentra necesario y esencial investigar sobre cada una de estas problemáticas y qué soluciones se pueden brindar. En este caso, la condición del pavimento.

6. Metodología

La metodología empleada en este estudio consta de 6 pasos principales:

Paso 1: Investigación del estado del arte. Se realizó un barrido sobre los temas de esta investigación en revistas científicas y demás repositorios de universidades internacionales sobre investigaciones similares a esta.

Paso 2: Se realizó una búsqueda de bases de datos que tuviesen características suficientes para describir siniestros viales en la ciudad de Bogotá, así como la condición del pavimento a lo largo de toda la malla vial.

Paso 3: Al encontrar las bases de datos, se debó hacer una limpieza de datos incompletos, para proceder a buscar la forma de correlacionar las dos bases identificadas en el paso 2.

Paso 4: Se inició con la construcción de la red neuronal. Se investiga sobre tipos de redes, se aprende a través de ejemplos de problemas de clasificación programados en Python. Se construye una Regresión Logística para comprar resultados.

Paso 5: Se analizan casos críticos de siniestralidad donde la variable a modificar es la condición del pavimento, estudiando si existen cambios significativos sobre la predicción de gravedad.

Paso 6: Se evalúan los resultados obtenidos de este análisis. Se llegan a conclusiones y recomendaciones para una posible continuación de la investigación.



Figura 1. Metodología de investigación.

7.Desarrollo

Conocer el estado del arte de esta investigación fue el inicio para abarcar en qué temas se debía tener un foco especial. Como se observa en la sección 3, China fue uno de los primeros lugares donde se exploró la aplicación de inteligencia artificial para solucionar problemas de transporte, en 2017. Sin embargo, los problemas de clasificación de todo tipo de índole ya estaban siendo solucionados bajo algoritmos de inteligencia artificial y redes neuronales. Es así como se inició el desarrollo de esta investigación.

7.1 Bases de datos

La ciudad de Bogotá posee distintos conjuntos o sets de datos, bajo los cuales analiza y toma decisiones en pro del beneficio de la ciudadanía. Cada día se vuelve una tarea primordial para cualquier entidad del distrito contar con datos cuantitativos para argumentar el por qué de una medida, campaña o proyecto. Es así como la Secretaría Distrital de Movilidad posee un equipo dedicado únicamente a analizar datos de tráfico, flujo, tiempos, y accidentes, es llamada la Dirección de Inteligencia para la Movilidad. La base a la que se necesitaba acceder es llamada IPAT, por sus siglas (Informe Policial de Accidentes de Tránsito), la cual es diligenciada por la Policía de Tránsito del Distrito en el lugar de ocurrencia de los siniestros viales. Esta base consigna datos personales como nombres, números de identificación, datos de notificación como teléfono; estos datos se protegen por la ley Habeas Data, pero a su vez, se consignan datos característicos del accidente, las cuales se pueden ver en la tabla 2. Número de formulario, código del accidente (si es un atropello, un volcamiento, etc), la fecha y hora de ocurrencia, la dirección y localidad donde se presentó, la **gravedad** (si el siniestro dejó un fallecido, algún herido o si solo fueron daños materiales), las coordenadas obtenidas desde sus dispositivos electrónicos de trabajo, el CIV o Código de Identificación Vial (el número de identificación de la calle donde se encuentra) y el PK de calzada, que también corresponde a la identificación de la calle.

Tabla 2. Variables del IPAT

Siniestralidad	Objeto ID
	Formulario
	Código Accidente
	Fecha ocurrencia
	Hora ocurrencia
	Año ocurrencia
	Mes ocurrencia
	Día ocurrencia
	Dirección
	Gravedad
	Clase accidente
	Localidad (2)
	Municipio
	Fecha y hora
	Latitud
	Longitud
	CIV
	PK Calzada

Esta base de datos posee registros desde el año 2006, en donde la SDM no existía, en su lugar estaba la Secretaría de Tránsito y Transporte, es así como se llega a un total de 412.000 registros, una vez eliminados los registros incompletos, mal diligenciados, o repetidos.

Ahora bien, el Instituto de Desarrollo Urbano (IDU), en el año 2016 lanzó una licitación pública para realizar el diagnóstico de la malla vial de la ciudad y así, poder priorizar sus programas de mantenimiento y brigadas de reparación. Esta licitación finalizó en 2017 y uno de sus productos fue una base de datos sobre el estado de la malla vial con las características que se pueden ver en la Tabla 3. Variables como CIV, PK Calzada, explicadas anteriormente, Superficie (Flexible, rígida, mixta), Clasificación de la Malla Vial (Arterial, Intermedia, Local), kilómetro carril de ese segmento de vía con el estado, PCI o *Pavement Index Condition* del 2017 (clasificación de 0 a 100) y, por último, el Estado de ese segmento, clasificado como Bueno, regular o Malo. Esta clasificación se puede ver en la Figura 2.

Tabla 3. Variables IDU Estado de la Malla Vial

Estado malla vial	Object ID
	CIV
	PK Calzada
	Superficie
	Clasificación
	Km carril
	PCI 2017
	Estado 2017
	Global ID

Se encuentra entonces una variable en común para las dos bases de datos, sobre la cual se pueden relacionar fácilmente, y así asignar a cada siniestro vial registrado, un estado de la malla vial desde 2017. Se entiende que el estado del pavimento es una condición dinámica, que cambia en poco tiempo, es así como la temporalidad debe estar contemporánea, y se realiza una segunda limpieza de la base, en donde los registros obtenidos antes del 2016 son eliminados. También se limpian CIV en blanco, y siniestros viales que no correspondan a ningún CIV que genere un estado. Al final, se obtiene una base conglomerada de cerca de 100.000 registros de siniestros, cada uno con características propias del estado del pavimento donde sucedió el mismo.

Clasificación PCI – Personalizada IDU	
	MAL ESTADO
	$0 \geq \text{PCI} \leq 55$
	REGULAR ESTADO
	$55 > \text{PCI} < 90$
	BUEN ESTADO
	$90 \geq \text{PCI} \leq 100$

Figura 2. Clasificación Estado según PCI - IDU.

7.2 Análisis base de datos

Debido a que esta base de datos será de donde se alimente y aprenda la red neuronal, se procedió a analizar la correlación que se realizó y así poder comprender mejor el comportamiento de los siniestros viales versus la condición del pavimento. Este análisis se hizo mediante ArcGIS, por medio de georreferenciación de las características, y se muestra a continuación.




Figura 3. Mapa georreferenciado - Estado del Pavimento
Fuente: Elaboración Propia

Esta georreferenciación fue posible ya que ambas bases de datos contaban con datos de coordenadas. En la Figura 3 se evidencia que las zonas con peor estado de la malla vial son en los extremos o límites de la ciudad, y en la localidad de Usme.



Figura 4. Mapa georreferenciado de siniestros viales
Fuente: Elaboración propia

En la figura 4 se puede ver la malla vial de fondo, en color negro, mientras que la concentración de siniestros viales sube en la tonalidad de colores rojos. Se evidencia entonces que donde se

encuentran vías arteriales es donde mayor cantidad de siniestros se registran. Por último, en la figura 5 encontramos una sobreposición de la figura 3 y 4, en donde se puede ver que no necesariamente las zonas con peor estado de la malla vial concentran una gran cantidad de siniestros viales. Esto ocurre ya que, a peor estado de la malla vial, menor es la velocidad a la que pueden transitar los vehículos motorizados, disminuyendo así la probabilidad de ocurrencia del siniestro.




Figura 5. Correlación Siniestralidad vial vs estado de la malla vial.
Fuente: Elaboración propia.

7.3 Construcción red neuronal

Para la construcción de la red neuronal se buscaron ejemplos de problemas de clasificación que se hayan resuelto por medio de redes neuronales multicapa convolucionales. En este caso, se programó en el programa Python, el cual ofrece librerías dedicadas al *Data Science*, al *Machine Learning* y a las redes neuronales en general.

Se inicia importando dichas librerías al archivo en el cuál se desarrollará el código, el cual se encuentra en el Anexo A: Código Red Neuronal. Una vez obtenidas, se inicia a la clasificación de variables predictoras, es decir, las variables que entraran como input de la red, de las cuales aprenderá para dar como resultado el output o predicción, en este caso las variables predictoras son:

- | | |
|----------------------|-----------------------------|
| - Hora | - Latitud |
| - Día | - Clasificación de la malla |
| - Mes | - Superficie |
| - Clase de accidente | - PCI |
| - Localidad | - Estado |
| - Longitud | |

Las variables que tienen por función identificar, no poseen un papel fundamental en el proceso del *Deep Learning* de la red neuronal, ya que es única en cada caso, por esto no se toman en cuenta el CIV o los IDs.

Seguido a esto, se dividen estas variables predictoras en categóricas y no categóricas, es decir, variables que tienen un intervalo definido de respuesta, o que pueden ser continuas en su respuesta. Aquí un ejemplo:

- Categóricas:
 - Día: Lunes, Martes, Miércoles, Jueves, Viernes, Sábado, Domingo
 - Mes: Enero, Febrero, Marzo, Abril, Mayo, Junio, Julio, Agosto, Septiembre, Octubre, Noviembre, Diciembre
 - Clase de accidente: Volcamiento, atropello, caída de ocupante, choque

- Localidad: Usaquén, Chapinero, Santa Fe, San Cristóbal, Usme, Tunjuelito, Bosa, Kennedy, Fontibón, Engativá, Suba, Barrios Unidos, Teusaquillo, Los Mártires, Antonio Nariño, Puente Aranda, La Candelaria, Rafael Uribe Uribe, Ciudad Bolívar y Sumapaz
- Clasificación Malla Vial: Arteria, Intermedia, Local o rural
- Superficie: Rígido, Flexible, mixta
- Estado: Bueno, regular, malo.
- No Categóricas:
 - Hora
 - Latitud
 - Longitud
 - PCI

Una vez clasificadas, las variables categóricas se convierten en “*dummies*”, es decir, variables de respuesta sí o no. La red neuronal pregunta: ¿Ocurrió en enero? Y la respuesta es 0 para sí, y 1 para no. Esto ocurre para todas las respuestas posibles de cada variable categórica, generando 55 variables de entrada a la red neuronal.

Terminado este proceso, se inicia con la arquitectura de la red neuronal. Se debe elegir el número de capas ocultas, el número de neuronas, el porcentaje de dropout, una función que previene el sobreajuste de los datos en el proceso de aprendizaje, y el gradiente por el cuál irá viajando la información, así como el número de épocas o iteraciones que tendrá la red. Antes de esto, se debió separar la totalidad de datos de entrada a la red entre datos para aprendizaje y datos para evaluación, 70 y 30% respectivamente. Esto quiere decir que del 100% de datos de entrada de la base correlacionada, el 70% estará enfocado en el aprendizaje de la red, mientras que el 30% lo usará para evaluar si su aprendizaje fue verídico o no. Finalmente, después de diversos intentos de prueba y error hasta encontrar un *accuracy* o veracidad alta en la red, la arquitectura elegida fue:

- 5 capas ocultas
- Número de neuronas por capa: 100, 200, 300, 200, 100
- Número de épocas: 100
- Batch size o gradiente: 1024

El resultado de una red neuronal se lee en una matriz de confusión. En las filas, se encuentran los datos de entrada, y en las columnas, los datos resultado de la predicción de la red. En este caso, la predicción corresponde a la gravedad de los siniestros viales. La matriz de confusión se ve en la siguiente figura.

Tabla 4. Matriz de confusión - red neuronal

	CON HERIDOS	CON MUERTOS	SOLO DAÑOS
CON HERIDOS	1622	49	1661
CON MUERTOS	90	1	68
SOLO DAÑOS	755	30	6119

Esto quiere decir que, de 3332 siniestros con heridos, la red clasificó correctamente 1622, es decir, el 48%. En el caso de siniestros con muertos, la red neuronal clasificó correctamente 1 solo siniestro, de los 159 de entrada. Y por último, en el caso de solo daños, la red clasificó correctamente 6119 de 6904, es decir, un 89%.

El último paso es corroborar la veracidad total de la red neuronal, esto se hace por medio de su accuracy o veracidad. La red neuronal construida para esta investigación resultó con un 79% de veracidad en su predicción.

```
In [47]: true_values = np.trace(cm)
false_values = np.sum(cm)-true_values
test_accuracy = true_values / (true_values+false_values)
test_accuracy

Out[47]: 0.7917267917267917
```

Figura 6. Veracidad NN – Python

Se evidencia que la veracidad general de la predicción de la red neuronal aumenta con el número de épocas ascendente. Tiende a converger en el número de época 44, manteniendo un intervalo de 84-85. Esto quiere decir que no se necesita una gran cantidad de iteraciones para que la red, con una buena arquitectura, genere buenas predicciones.

7.4 Construcción Regresión Logística

Una regresión logística es el análogo de una regresión lineal, pero para problemas de clasificación multivariantes y en varias dimensiones. Esta regresión se realiza como método de comparación de la red neuronal, para entender si el problema se puede resolver más verídicamente por medio de una regresión, o si arroja mejores resultados por medio de una red neuronal.

En la regresión logística ingresan las 55 variables ya convertidas en dummies, proceso descrito en la sección 7.3, y se obtiene un pseudo r^2 , el cual corresponde a una métrica de ajuste de los datos a la regresión, pero debido a que este caso es en varias dimensiones, es complejo llegar cerca al 100%. Sin embargo, la regresión arroja otro valor que útil para esta investigación, y es el p -value de cada una de las variables. Este p -value entre más cercano sea a 0, mejor explicará el fenómeno que se está analizando, y así se corrobora que los predictores elegidos para la red neuronal están correctos y explican a cabalidad el fenómeno. Estos resultados se encuentran en el Anexo B. Regresión logística, y se sintetizan a continuación:

- Hora
- Localidad
- Meses
- Día
- PCI

La regresión logística también arroja una matriz de confusión y una veracidad total, para este caso, la red neuronal provee una veracidad mayor, tanto en cada caso específico de gravedad como en general.

Tabla 5. Matriz de confusión - Regresión Logística

	CON HERIDOS	CON MUERTOS	SOLO DAÑOS
CON HERIDOS	1387	0	1945
CON MUERTOS	86	0	73
SOLO DAÑOS	21	0	6883

```
In [22]: true_values = np.trace(cm)
false_values = np.sum(cm)-true_values
test_accuracy = true_values / (true_values+false_values)
test_accuracy
```

```
Out[22]: 0.7447811447811448
```

Figura 7. Veracidad de la regresión logística.

7.5 Análisis de sensibilidad

Al construir y optimizar la red neuronal, y saber que su veracidad es alta, se procede a analizar diferentes casos, variando la condición del estado del pavimento para conocer si genera un cambio importante. Se inicia entonces evaluando las peores condiciones de siniestralidad según los anuarios de siniestralidad de la ciudad de Bogotá. Se obtienen entonces las siguientes condiciones:

1. El día corresponde a el viernes
2. La hora corresponde a las 7:00 am
3. El mes corresponde a junio
4. La localidad con mayor concentración de siniestros es Kennedy
5. La clase de accidente más común es el choque
6. La superficie de pavimento en donde más se registran siniestros es en el flexible
7. La malla vial más riesgosa es la arterial

Con este conjunto de condiciones con alta siniestralidad se procede a ingresarlas en la red neuronal y examinar la predicción que arroja, variando los valores del PCI de 5 en 5. La predicción en este caso será la probabilidad de gravedad del siniestro descrito por esas variables. Estos resultados se pueden ver en la tabla 4.

Tabla 6. Análisis de sensibilidad - PCI

<i>Probabilidad</i>	<i>PCI 100</i>	<i>PCI 95</i>	<i>PCI 90</i>	<i>PCI 85</i>	<i>PCI 80</i>	<i>PCI 75</i>	<i>PCI 70</i>	<i>PCI 65</i>	<i>PCI 60</i>	<i>PCI 55</i>	<i>PCI 50</i>	<i>PCI 45</i>	<i>PCI 40</i>	<i>PCI 35</i>	<i>PCI 30</i>	<i>PCI 25</i>	<i>PCI 20</i>	<i>PCI 15</i>	<i>PCI 10</i>
<i>Solo daños</i>	0.24 396	0.24 23	0.24 631	0.31 619	0.30 679	0.30 291	0.29 797	0.29 451	0.28 597	0.31 268	0.31 404	0.31 346	0.30 521	0.3 145	0.29 643	0.28 396	0.28 728	0.27 98	0.26
<i>Con heridos</i>	0.00 034	0.00 029	0.00 027	0.00 023	0.00 021	0.00 02	0.00 022	0.00 026	0.28 597	0.01 046	0.00 921	0.00 812	0.00 602	0.00 403	0.00 266	0.00 178	0.00 124	0.00 086	0.00 062
<i>Con muertos</i>	0.75 569	0.75 741	0.75 342	0.68 358	0.69 3	0.69 689	0.70 182	0.70 523	0.71 373	0.67 685	0.67 675	0.67 842	0.68 877	0.69 596	0.70 589	0.71 179	0.71 48	0.72 186	0.72 958




Figura 8. Visualización del análisis de sensibilidad – PCI

Al ir variando el PCI de mayor a menor valor el comportamiento de cada gravedad es distinto, pero posee límites que reflejan la escala por la que se cataloga el estado de la malla vial como “bueno”, “regular” o “malo” (véase figura 2). En la gravedad “con muertos” se inicia desde una alta probabilidad, el 80%, que se mantiene constante hasta que el estado cambia, es decir, en el PCI de valor 90. En el tramo en donde el PCI cataloga una vía como “regular” aumenta 3%, para volver a decaer en el límite donde cambia al estado “malo”, es decir, en el PCI con valor 55. Y finalmente, cuando el PCI se encuentra en valores de estado “malo” vuelve a aumentar, esta vez en 5%.

En términos de siniestralidad, en los PCI más altos, la velocidad de los vehículos es mayor debido a la percepción de regularidad y homogeneidad de la capa superficial del pavimento, se siente comodidad y seguridad, y es ahí donde por algún factor que influya, como la iluminación, un peatón, un animal, etc es posible llegar a un siniestro fatal o “con muertos”. A medida que disminuye el PCI, se va disminuyendo ese deseo del conductor de ganar velocidad, y empieza a prestar más atención a obstáculos mínimos del pavimento, disminuyendo la probabilidad de generar un siniestro “con heridos”. Y en contra de toda intuición, la probabilidad de que exista una fatalidad aumenta cuando el PCI disminuye hasta llegar al final del intervalo. Al verlo de forma general, la probabilidad disminuye en un 3% al disminuir el PCI, esto teniendo explicación en la disminución de velocidad que es, según la literatura (SDM, 2018) el factor preponderante en el desenlace de un siniestro vial. Sin embargo, este análisis no infiere que las calles de la ciudad no deban tener un buen PCI, al contrario, la calidad de las vías está directamente

relacionado con el progreso y la eficiencia en el transporte de Bogotá, es por esto que un PCI alto debe ir acompañado de intervenciones integrales de demarcación horizontal, medidas de pacificación cuando sea necesario, señalética y señalización vertical para indicar las normas del tramo vial, y cultura ciudadana.

El siguiente análisis que se realizó fue variando la superficie del pavimento entre adoquín de arcilla, adoquín de concreto, afirmado, pavimento flexible, pavimento rígido y mixto, bajo las mismas condiciones de alta siniestralidad descritas anteriormente. El resultado se puede ver en la Tabla 5.

Tabla 7. Análisis de sensibilidad - variación superficie

Probabilidad	Adoquín arcilla	Adoquín concreto	Afirmado	Flexible	Mixto	Rígido
Con heridos	0.04604	0.18663	0.00922	0.04325	0.73683	0.04604
Con muertos	0.00001	0.00001	0.00001	0.00001	0.00001	0.00001
solo daños	0.95395	0.81336	0.99078	0.95675	0.26317	0.95395




Figura 9. Visualización del análisis de sensibilidad – superficie

Ahora bien, variando la superficie el comportamiento genera cambios súbitos. En el caso de siniestro fatal, no existe variación de ninguna clase, se podría decir que el siniestro fatal no depende del tipo de superficie en el que suceda. Es diferente para el caso de siniestro con heridos, el cual inicia con una probabilidad del 4.6% en adoquín de arcilla, pero aumenta a 18.6% en adoquín de concreto. Disminuye a 1% cuando se registra en afirmado, y aumenta en 3% para

la superficie de pavimento flexible. No obstante, el cambio más drástico es del orden de 69 puntos porcentuales cuando cambia al tipo de pavimento “mixto”, para volver a disminuir al 4.6% en la superficie de pavimento rígido. Para futuras investigaciones se podría verificar si la rugosidad juega un papel importante en este tipo de siniestro. Asimismo, se debe ahondar en el tipo de pavimento clasificado como “mixto”, ya que el IDU lo define como la superficie que no es ni adoquín, ni flexible, ni rígido.

Y, en el caso de siniestros “solo daños”, el comportamiento es el siguiente: Inicia con un 95% de probabilidad en una superficie de adoquín de arcilla, pasa después a un 81% sobre el adoquín de cemento y aumenta al 99% en afirmado, esto es una bandera roja para el distrito, ya que con el hecho de pavimentar, podrían disminuir la cantidad de siniestros “solo daños”, los cuales generan externalidades importantes en el tránsito, así como pérdidas económicas tanto para el actor vial involucrado como para la ciudad. Aún así, existe una probabilidad del 95% de que ocurra un siniestro “solo daños” en superficie flexible, esto explicado como la superficie más usada en toda la ciudad; esta probabilidad es la misma para la superficie de pavimento rígido, usada en vías como la autopista norte, los carriles exclusivos de Transmilenio de todas las troncales menos la Calle 80, por nombrar algunos ejemplos. Ahora, en el caso de la superficie mixta, es donde disminuye en mayor proporción la probabilidad, con un 26%. Genera entonces la duda, ¿qué características físicas tiene la superficie de pavimento mixto según el IDU para que en el caso de siniestros “con heridos” y “solo daños” corresponda a la mayor reducción de probabilidad de ocurrencia?

8. Conclusiones y recomendaciones

8.1 Conclusiones

- La red neuronal posee una buena veracidad ya que acierta en la mayor cantidad de eventos, los cuales se clasifican en “solo daños”. Para el caso de siniestros “con heridos” y “con muertos”, debido a que son menos datos en proporción, disminuye su veracidad individual, pero no afecta a la veracidad de la red en general.
- La condición del pavimento no es un punto de cambio en el riesgo que influye en la gravedad del siniestro. Se cree que la velocidad vehicular sí es una variable sensible, ya que podría predecir el riesgo presente en la zona. Para esto se debe tener en cuenta los conceptos de riesgo y amenaza. No obstante, en la actualidad no existe información sobre la velocidad de los vehículos involucrados en este tipo de eventos.
- Se catalogó como dificultad encontrar fuentes de datos públicas, actualizadas, accesibles, georreferenciadas y verídicas. Si existieran, se habrían podido relacionar más variables como velocidad, iluminación, seguridad ciudadana, etc.
- La mejora del PCI aumenta en 3% la probabilidad de ocurrencia de un siniestro grave (velocidades mayores), sin embargo, no se quiere decir que no se deban tener vías con altos PCI, se requiere una intervención integral en donde la condición del pavimento sea superior, señalización y demarcación estén acorde al contexto de ciudad donde se encuentre y así, se priorice la seguridad vial.
- La superficie de pavimento mixta es la que tiene mayor probabilidad de que el siniestro involucre heridos, asumiendo condiciones críticas de siniestros viales. No obstante, la definición de superficie de pavimento no es clara según el Instituto de Desarrollo Urbano, ya que asegura que es la superficie que no corresponde a flexible, rígido o articulado.

- Al disminuir el PCI, la probabilidad de que el siniestro involucre “solo daños”, aumenta en un 5%, es decir que de 10 siniestros con solo daños, se podrían evitar 5 solo con mejorar el estado del pavimento.

8.2 Recomendaciones

A continuación, se presenta una serie de aspectos que se podrían realizar en un futuro para emprender investigaciones similares o fortalecer la investigación realizada:

1. Es necesario involucrar un análisis de riesgo y amenaza en la red neuronal, que determine los factores de riesgo y las amenazas que desencadenen.
2. La velocidad es una variable vehicular es muy importante, si las entidades tuviesen esta información, se podría llegar a resultados más allegados a la realidad.
3. Los modelos existentes sobre siniestralidad versus condición del pavimento son probabilísticos. Entrar al mundo de la inteligencia artificial se abren las puertas a respuestas que aún no se tienen, como la importancia de intervenciones pequeñas de mantenimiento superficial.
4. La finalidad es lograr que se armonicen las entidades del distrito para lograr salvar vidas, disminuir cantidad de heridos y accidentes simples.
5. Intentarlo y no lograrlo está bien, evidencia oportunidades de mejora.

A. Anexo: Código Red Neuronal

Librerías

```
In [9]: # Data Science
import pandas as pd
import numpy as np

# Machine Learning
import statsmodels.api as sm
from sklearn import preprocessing
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split
from sklearn import metrics
from sklearn.metrics import confusion_matrix, roc_auc_score, roc_curve, classification_r
eport, multilabel_confusion_matrix

# Redes Neuronales
import tensorflow as tf
from tensorflow.keras import Sequential
from tensorflow.keras.layers import Dense, Dropout

# Visualización
import matplotlib.pyplot as plt
import seaborn as sns

# Configuración
pd.set_option('display.max_columns', 500)
pd.set_option('display.max_rows', 500)
```


Datos

```
In [10]: dataset = pd.read_excel("Accidente + estado malla vial.xlsx", encoding="latin-1")
print("Tamaño de la base inicial", dataset.shape)
dataset.head(3)
```

Tamaño de la base inicial (400952, 23)

Out[10]:

	OBJECTID	FORMULARIO	CODIGO_ACC	FECHA_OCUR	HORA_OCURRE	ANO_OCURRE	MES_OCURRE	DI
0	411102.0	A000641616	4493998.0	2017-09-18	08:20:00	2017.0	SEPTIEMBRE	
1	410988.0	A000690861	4500524.0	2017-11-21	16:30:00	2017.0	NOVIEMBRE	
2	411753.0	A000605128	4484429.0	2017-06-10	18:30:00	2017.0	JUNIO	



```
In [11]: dataset = dataset[["GRAVEDAD", "HORA_OCURRE", "MES_OCURRE", "DIA_OCURRE", "CLASE_ACC", "LOCALI
DAD",
                        "LATITUD", "LONGITUD", "Clasificación Malla Vial", "Superficie", "PCI", "Estado"]]

dataset = dataset.dropna()

dataset["HORA_OCURRE"] = dataset["HORA_OCURRE"].apply(lambda x: int(x[:2])*60+int(x[3:5]))

categoricas = ["MES_OCURRE", "DIA_OCURRE", "CLASE_ACC", "LOCALIDAD", "Clasificación Malla Vi
al",
              "Superficie", "Estado"]

for cat in categoricas:
    dataset[cat] = dataset[cat].replace(dataset[cat].unique()[0], np.nan)

numericas = [a for a in dataset.columns.tolist() if a not in categoricas]
```

```
In [12]: dataset_model = pd.get_dummies(dataset[[a for a in dataset.columns.tolist() if a != "GRA
VEDAD"]])
print("Tamaño de la base después de eliminar vacíos", dataset_model.shape)
dataset_model.head(3)
```

Tamaño de la base después de eliminar vacíos (34647, 64)

Out[12]:

	HORA_OCURRE	LATITUD	LONGITUD	PCI	MES_OCURRE_ABRIL	MES_OCURRE_AGO	MES_OCURRE
0	500	4.633808	-74.163708	100.0	0	0	
1	990	4.624994	-74.148136	100.0	0	0	
2	1110	4.649240	-74.147050	100.0	0	0	

```
In [13]: lista_malos = dataset_model.sum(axis=0).reset_index().sort_values(by=0)
lista_malos = lista_malos[abs(lista_malos[0])<100]["index"].tolist()

y = dataset["GRAVEDAD"]
X = dataset_model[[a for a in dataset_model.columns.tolist() if a not in lista_malos]]

datos_totales = X.copy()
datos_totales["GRAVEDAD"] = y
```

Separación de datos

```
In [14]: # Estandarización de los datos
sc = StandardScaler()
X = sc.fit_transform(X)
```

```
In [15]: # Separación en Train y Test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state =
1608)
```

Red Neuronal

```
In [16]: classifier = Sequential()

#First Hidden Layer
classifier.add(Dense(200, activation='relu', input_dim=55))

#Second Hidden Layer
classifier.add(Dense(300, activation='relu'))

#Dropout Layer
classifier.add(Dropout(0.35))

#Third Hidden Layer
classifier.add(Dense(400, activation='relu'))

#Dropout Layer
classifier.add(Dropout(0.35))

#Fourth Hidden Layer
classifier.add(Dense(300, activation='relu'))

#Fifth Hidden Layer
classifier.add(Dense(200, activation='relu'))

#Dropout Layer
classifier.add(Dropout(0.35))

#Output Layer
classifier.add(Dense(3, activation='softmax'))
```

```
In [17]: #Compiling the neural network
classifier.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```

```
In [18]: #Fitting the data to the training dataset
classifier.fit(X_train, pd.get_dummies(y_train).values, batch_size=2048, epochs=50)
```

```
Epoch 1/50
12/12 [=====] - 1s 66ms/step - loss: 0.7594 - accuracy: 0.6462
Epoch 2/50
12/12 [=====] - 1s 67ms/step - loss: 0.6178 - accuracy: 0.7467
Epoch 3/50
12/12 [=====] - 1s 68ms/step - loss: 0.5500 - accuracy: 0.7918
Epoch 4/50
12/12 [=====] - 1s 64ms/step - loss: 0.5233 - accuracy: 0.7997
Epoch 5/50
12/12 [=====] - 1s 64ms/step - loss: 0.5154 - accuracy: 0.8006
Epoch 6/50
12/12 [=====] - 1s 65ms/step - loss: 0.5127 - accuracy: 0.8013
Epoch 7/50
12/12 [=====] - 1s 66ms/step - loss: 0.5077 - accuracy: 0.8012
Epoch 8/50
12/12 [=====] - 1s 65ms/step - loss: 0.5021 - accuracy: 0.8016
Epoch 9/50
12/12 [=====] - 1s 66ms/step - loss: 0.4989 - accuracy: 0.8021
```

```
Epoch 10/50
12/12 [=====] - 1s 66ms/step - loss: 0.4973 - accuracy: 0.8014
Epoch 11/50
12/12 [=====] - 1s 68ms/step - loss: 0.4929 - accuracy: 0.8018
Epoch 12/50
12/12 [=====] - 1s 65ms/step - loss: 0.4898 - accuracy: 0.8032
Epoch 13/50
12/12 [=====] - 1s 64ms/step - loss: 0.4857 - accuracy: 0.8033
Epoch 14/50
12/12 [=====] - 1s 65ms/step - loss: 0.4817 - accuracy: 0.8053
Epoch 15/50
12/12 [=====] - 1s 65ms/step - loss: 0.4781 - accuracy: 0.8046
Epoch 16/50
12/12 [=====] - 1s 67ms/step - loss: 0.4750 - accuracy: 0.8051
Epoch 17/50
12/12 [=====] - 1s 67ms/step - loss: 0.4734 - accuracy: 0.8061
Epoch 18/50
12/12 [=====] - 1s 66ms/step - loss: 0.4702 - accuracy: 0.8081
Epoch 19/50
12/12 [=====] - 1s 65ms/step - loss: 0.4627 - accuracy: 0.8079
Epoch 20/50
12/12 [=====] - 1s 66ms/step - loss: 0.4609 - accuracy: 0.8093
Epoch 21/50
12/12 [=====] - 1s 66ms/step - loss: 0.4552 - accuracy: 0.8113
Epoch 22/50
12/12 [=====] - 1s 66ms/step - loss: 0.4523 - accuracy: 0.8128
Epoch 23/50
12/12 [=====] - 1s 65ms/step - loss: 0.4464 - accuracy: 0.8135

Epoch 24/50
12/12 [=====] - 1s 66ms/step - loss: 0.4438 - accuracy: 0.8140
Epoch 25/50
12/12 [=====] - 1s 67ms/step - loss: 0.4336 - accuracy: 0.8177
Epoch 26/50
12/12 [=====] - 1s 65ms/step - loss: 0.4333 - accuracy: 0.8173
Epoch 27/50
12/12 [=====] - 1s 65ms/step - loss: 0.4293 - accuracy: 0.8178
Epoch 28/50
12/12 [=====] - 1s 66ms/step - loss: 0.4263 - accuracy: 0.8180
Epoch 29/50
12/12 [=====] - 1s 67ms/step - loss: 0.4248 - accuracy: 0.8197
Epoch 30/50
12/12 [=====] - 1s 66ms/step - loss: 0.4181 - accuracy: 0.8224
Epoch 31/50
12/12 [=====] - 1s 66ms/step - loss: 0.4134 - accuracy: 0.8228

Epoch 33/50
12/12 [=====] - 1s 66ms/step - loss: 0.4055 - accuracy: 0.8270
Epoch 34/50
12/12 [=====] - 1s 66ms/step - loss: 0.3987 - accuracy: 0.8284
Epoch 35/50
12/12 [=====] - 1s 66ms/step - loss: 0.3955 - accuracy: 0.8307
Epoch 36/50
12/12 [=====] - 1s 66ms/step - loss: 0.3891 - accuracy: 0.8311
Epoch 37/50
12/12 [=====] - 1s 70ms/step - loss: 0.3878 - accuracy: 0.8319
```

```

Epoch 38/50
12/12 [=====] - 1s 81ms/step - loss: 0.3795 - accuracy: 0.8362
Epoch 39/50
12/12 [=====] - 1s 94ms/step - loss: 0.3803 - accuracy: 0.8354
Epoch 40/50
12/12 [=====] - 1s 69ms/step - loss: 0.3745 - accuracy: 0.8366
Epoch 41/50
12/12 [=====] - 1s 69ms/step - loss: 0.3740 - accuracy: 0.8387
Epoch 42/50
12/12 [=====] - 1s 69ms/step - loss: 0.3689 - accuracy: 0.8391
Epoch 43/50
12/12 [=====] - 1s 70ms/step - loss: 0.3632 - accuracy: 0.8443
Epoch 44/50
12/12 [=====] - 1s 70ms/step - loss: 0.3612 - accuracy: 0.8458
Epoch 45/50
12/12 [=====] - 1s 73ms/step - loss: 0.3548 - accuracy: 0.8445
Epoch 46/50
12/12 [=====] - 1s 73ms/step - loss: 0.3483 - accuracy: 0.8511
Epoch 47/50
12/12 [=====] - 1s 70ms/step - loss: 0.3472 - accuracy: 0.8491
Epoch 48/50
12/12 [=====] - 1s 72ms/step - loss: 0.3409 - accuracy: 0.8501
Epoch 49/50
12/12 [=====] - 1s 76ms/step - loss: 0.3344 - accuracy: 0.8544
Epoch 50/50
12/12 [=====] - 1s 74ms/step - loss: 0.3337 - accuracy: 0.8557

```

Out[18]: <tensorflow.python.keras.callbacks.History at 0x246d5b59588>

```
In [19]: y_pred = classifier.predict(X_test)
```

```
In [20]: y_pred = classifier.predict(X_test)
y_pred = y_pred.argmax(axis=1)
y_pred = [pd.get_dummies(y_train).columns[a] for a in y_pred]
```

```
In [21]: cm = confusion_matrix(y_test, y_pred)
pd.DataFrame(cm, columns=pd.get_dummies(y_train).columns, index = pd.get_dummies(y_train).columns)
```

Out[21]:

	CON HERIDOS	CON MUERTOS	SOLO DANOS
CON HERIDOS	1622	49	1661
CON MUERTOS	90	1	68
SOLO DANOS	755	30	6119

```
In [22]: true_values = np.trace(cm)
false_values = np.sum(cm)-true_values
test_accuracy = true_values / (true_values+false_values)
test_accuracy
```

Out[22]: 0.7447811447811448

```
In [23]: def process_one(user_example = None):
    if user_example == None:
        user_example = [0]*55
        columns = dataset_model[[a for a in dataset_model.columns.tolist() if a not in lista_malos]].columns.tolist()
        for idx, var in enumerate(columns):
            user_example[idx] = input("Enter {}: ".format(var))
        vec = np.array(user_example).reshape(1,55)
        transformed_vec = sc.transform(vec)
        return pd.DataFrame(data={'Gravedad': ['CON HERIDOS', 'CON MUERTOS', 'SOLO DANOS'],
                                'Probabilidad': classifier.predict_proba(transformed_vec)[0]}).round(5)
```

```
In [30]: # Read example from excel
ex = pd.read_excel('EjemplosNN.xlsx')
df = []
for col in ex.columns.tolist()[1:]:
    print('Example:', col)
    curr_df = process_one(ex[col].tolist())
    df.append(curr_df)
    print(curr_df)
    print('-----+')
```

Example: Adoquín arcilla

	Gravedad	Probabilidad
0	CON HERIDOS	0.04604
1	CON MUERTOS	0.00001
2	SOLO DANOS	0.95395

+-----+

Example: Adoquín concreto

	Gravedad	Probabilidad
0	CON HERIDOS	0.18663
1	CON MUERTOS	0.00000
2	SOLO DANOS	0.81336

+-----+

Example: Afirmado

	Gravedad	Probabilidad
0	CON HERIDOS	0.00922
1	CON MUERTOS	0.00000
2	SOLO DANOS	0.99078

+-----+

Example: Flexible

	Gravedad	Probabilidad
0	CON HERIDOS	0.04325
1	CON MUERTOS	0.00000
2	SOLO DANOS	0.95675

+-----+

Example: Mixto

	Gravedad	Probabilidad
0	CON HERIDOS	0.73683
1	CON MUERTOS	0.00000
2	SOLO DANOS	0.26317

+-----+

Example: Rígido

	Gravedad	Probabilidad
0	CON HERIDOS	0.04604
1	CON MUERTOS	0.00001
2	SOLO DANOS	0.95395

+-----+

```
In [32]: random_num = 1500
example = dataset_model[[a for a in dataset_model.columns.tolist() if a not in lista_malos]].iloc[random_num].tolist()
process_one()
```

```
Enter HORA_OCURRE:660
Enter LATITUD:4.63
Enter LONGITUD:-73.16
Enter PCI:65
Enter MES_OCURRE_ABRIL:1
Enter MES_OCURRE_AGOSTO:0
Enter MES_OCURRE_DICIEMBRE:0
Enter MES_OCURRE_ENERO:0
Enter MES_OCURRE_FEBRERO:0
Enter MES_OCURRE_JULIO:0
Enter MES_OCURRE_JUNIO:0
Enter MES_OCURRE_MARZO:0
Enter MES_OCURRE_MAYO:0
Enter MES_OCURRE_NOVIEMBRE:0
Enter MES_OCURRE_OCTUBRE:0
Enter DIA_OCURRE_DOMINGO:0
Enter DIA_OCURRE_JUEVES:0
Enter DIA_OCURRE_MARTES:0
Enter DIA_OCURRE_MIERCOLES:0
Enter DIA_OCURRE_SABADO:0
Enter DIA_OCURRE_VIERNES:0
Enter CLASE_ACC_ATROPELLO:0
Enter CLASE_ACC_CAIDA DE OCUPANTE:0
Enter CLASE_ACC_OTRO:0
Enter CLASE_ACC_VOLCAMIENTO:1
Enter LOCALIDAD_ANTONIO NARIÑO:0
Enter LOCALIDAD_BARRIOS UNIDOS:0
Enter LOCALIDAD_BOSA:0
Enter LOCALIDAD_CANDELARIA:0
Enter LOCALIDAD_CHAPINERO:1
Enter LOCALIDAD_CIUADAD BOLIVAR:0
Enter LOCALIDAD_ENGATIVA:0
Enter LOCALIDAD_FONTIBON:0
Enter LOCALIDAD_LOS MARTIRES:0
Enter LOCALIDAD_PUENTE ARANDA:0
Enter LOCALIDAD_RAFAEL URIBE URIBE:0
Enter LOCALIDAD_SAN CRISTOBAL:0
Enter LOCALIDAD_SANTA FE:0
Enter LOCALIDAD_SUBA:0
Enter LOCALIDAD_TEUSAQUILLO:0
Enter LOCALIDAD_TUNJUELITO:0
Enter LOCALIDAD_USAQUEN:0
Enter LOCALIDAD_USME:0
Enter Clasificación Malla Vial_Arterial:0
Enter Clasificación Malla Vial_Intermedia:1
Enter Clasificación Malla Vial_Local:0
Enter Superficie_Adoquín Arcilla:0
Enter Superficie_Adoquín Concreto:0
Enter Superficie_Afirmado:0
Enter Superficie_Flexible:1
Enter Superficie_Mixtos:0
Enter Superficie_Sin PCI:0
Enter Estado_MALO:0
Enter Estado_REGULAR:0
Enter Estado_SIN PCI:0
```

Out[32]:

	Gravedad	Probabilidad
0	CON HERIDOS	0.95711
1	CON MUERTOS	0.00513
2	SOLO DANOS	0.03776

B. Anexo: Código Regresión Logística

Regresión Logística

```
In [18]: for idx,i in enumerate(dataset_model[[a for a in dataset_model.columns.tolist() if a not in lista_malos]].columns):  
         print(idx+1,i)
```

```
1 HORA_OCURR  
2 LATITUD  
3 LONGITUD  
4 PCI  
5 MES_OCURRE_ABRIL  
6 MES_OCURRE_AGO  
7 MES_OCURRE_DIC  
8 MES_OCURRE_ENE  
9 MES_OCURRE_FEB  
10 MES_OCURRE_JUL  
11 MES_OCURRE_JUN  
12 MES_OCURRE_MAR  
13 MES_OCURRE_MAY  
14 MES_OCURRE_NOV  
15 MES_OCURRE_OCT  
16 DIA_OCURRE_DOM  
17 DIA_OCURRE_JUE  
18 DIA_OCURRE_MAR  
19 DIA_OCURRE_MIE  
20 DIA_OCURRE_SAB  
21 DIA_OCURRE_VIE  
22 CLASE_ACC_ATROPELLO  
23 CLASE_ACC_CAIDA DE OCUPANTE  
24 CLASE_ACC_OTRO  
25 CLASE_ACC_VOLCAMIENTO  
26 LOCALIDAD_ANTONIO NARIÑO  
27 LOCALIDAD_BARRIOS UNIDOS  
28 LOCALIDAD_BOSA  
  
29 LOCALIDAD_CANDELARIA  
30 LOCALIDAD_CHAPINERO  
31 LOCALIDAD_CIUADAD BOLIVAR  
32 LOCALIDAD_ENGATIVA  
33 LOCALIDAD_FONTIBON  
34 LOCALIDAD_LOS MARTIRES  
35 LOCALIDAD_PUENTE ARANDA  
36 LOCALIDAD_RAFAEL URIBE URIBE  
37 LOCALIDAD_SAN CRISTOBAL  
38 LOCALIDAD_SANTA FE  
39 LOCALIDAD_SUBA  
40 LOCALIDAD_TEUSAQUILLO  
41 LOCALIDAD_TUNJUELITO  
42 LOCALIDAD_USAQUEN  
43 LOCALIDAD_USME  
44 Clasificación Malla Vial Arterial  
45 Clasificación Malla Vial Intermedia  
46 Clasificación Malla Vial Local  
47 Superficie_Adoquillo Arcilla  
48 Superficie_Adoquillo Concreto  
49 Superficie_Afirmado  
50 Superficie_Flexible  
51 Superficie_Mixtos  
52 Superficie_sin PCI  
53 Estado_MALO  
54 Estado_REGULAR  
55 Estado_SIN PCI
```

```
In [19]: probas_logit = []
posiciones = pd.get_dummies(y_train).columns.tolist()

for pos in posiciones:
    print(pos)

    logit_model=sm.Logit((y_train==pos)*1,X_train)
    result=logit_model.fit()
    print(result.summary2())

logreg = LogisticRegression()
logreg.fit(X_train, (y_train==pos)*1)
proba = logreg.predict_proba(X_test)[: ,1]
probas_logit.append(proba)
```

CON HERIDOS

Optimization terminated successfully.

Current function value: 0.468149

Iterations 8

Results: Logit

```
=====
Model:                Logit                Pseudo R-squared: 0.238
Dependent Variable:    GRAVEDAD              AIC:                22817.0899
Date:                 2021-01-28 12:01       BIC:                23262.3839
No. Observations:     24252                 Log-Likelihood:     -11354.
Df Model:             54                    LL-Null:            -14904.
Df Residuals:         24197                 LLR p-value:        0.0000
Converged:            1.0000                 Scale:             1.0000
No. Iterations:       8.0000

-----
```

	Coef.	Std.Err.	z	P> z	[0.025	0.975]
x1	-0.0564	0.0164	-3.4284	0.0006	-0.0886	-0.0242
x2	-0.3599	0.5262	-0.6839	0.4940	-1.3912	0.6715
x3	-0.3486	0.5244	-0.6648	0.5062	-1.3763	0.6792
x4	0.0315	0.0525	0.5994	0.5489	-0.0715	0.1345
x5	-0.0455	0.0220	-2.0663	0.0388	-0.0887	-0.0023
x6	-0.0252	0.0222	-1.1351	0.2563	-0.0688	0.0183
x7	-0.0460	0.0224	-2.0558	0.0398	-0.0899	-0.0021
x8	-0.0226	0.0219	-1.0324	0.3019	-0.0655	0.0203
x9	-0.0526	0.0231	-2.2798	0.0226	-0.0977	-0.0074
x10	-0.0363	0.0222	-1.6406	0.1009	-0.0798	0.0071
x11	-0.0255	0.0217	-1.1728	0.2409	-0.0681	0.0171
x12	-0.0496	0.0229	-2.1681	0.0302	-0.0944	-0.0048
x13	-0.0614	0.0229	-2.6810	0.0073	-0.1063	-0.0165
x14	-0.0229	0.0223	-1.0306	0.3027	-0.0666	0.0207
x15	-0.0200	0.0223	-0.8982	0.3691	-0.0638	0.0237
x16	0.0269	0.0202	1.3312	0.1831	-0.0127	0.0666
x17	0.0170	0.0223	0.7628	0.4456	-0.0267	0.0608
x18	0.0140	0.0225	0.6217	0.5341	-0.0301	0.0580
x19	-0.0071	0.0224	-0.3154	0.7525	-0.0510	0.0368
x20	-0.0284	0.0224	-1.2660	0.2055	-0.0722	0.0155
x21	-0.0278	0.0230	-1.2105	0.2261	-0.0728	0.0172
x22	1.1530	0.0253	45.6588	0.0000	1.1035	1.2025
x23	5.9251	0.1133	52.3173	0.0000	5.7032	6.1471
x24	0.2559	0.0260	9.8442	0.0000	0.2050	0.3069
x25	0.2249	0.0134	16.8124	0.0000	0.1987	0.2511
x26	0.0293	0.0167	1.7585	0.0787	-0.0034	0.0619
x27	-0.1594	0.0224	-7.1240	0.0000	-0.2032	-0.1155
x28	0.0171	0.0183	0.9391	0.3477	-0.0186	0.0529
x29	-0.0721	0.0200	-3.6034	0.0003	-0.1113	-0.0329
x30	-0.2323	0.0232	-10.0282	0.0000	-0.2778	-0.1869

x31	-0.0048	0.0199	-0.2414	0.8093	-0.0438	0.0342
x32	-0.0938	0.0265	-3.5358	0.0004	-0.1458	-0.0418
x33	-0.1545	0.0225	-6.8726	0.0000	-0.1985	-0.1104
x34	-0.0837	0.0192	-4.3514	0.0000	-0.1214	-0.0460
x35	-0.0254	0.0191	-1.3319	0.1829	-0.0628	0.0120
x36	0.0347	0.0180	1.9329	0.0532	-0.0005	0.0699
x37	0.0468	0.0173	2.7109	0.0067	0.0130	0.0806
x38	-0.0547	0.0188	-2.9094	0.0036	-0.0916	-0.0179
x39	-0.0867	0.0312	-2.7794	0.0054	-0.1478	-0.0256
x40	-0.1152	0.0198	-5.8295	0.0000	-0.1539	-0.0765
x41	0.0413	0.0170	2.4361	0.0148	0.0081	0.0746
x42	-0.2255	0.0343	-6.5765	0.0000	-0.2927	-0.1583
x43	-0.0199	0.0205	-0.9733	0.3304	-0.0601	0.0202
x44	0.0140	0.0301	0.4663	0.6410	-0.0450	0.0730
x45	0.1453	0.0264	5.4925	0.0000	0.0934	0.1971
x46	0.0640	0.0250	2.5626	0.0104	0.0151	0.1130
x47	-0.0245	0.0201	-1.2221	0.2217	-0.0638	0.0148
x48	-0.0214	0.0198	-1.0816	0.2794	-0.0601	0.0174
x49	0.0054	0.0195	0.2791	0.7801	-0.0327	0.0436
x50	0.0128	0.0222	0.5780	0.5633	-0.0307	0.0564
x51	0.0018	0.0169	0.1038	0.9173	-0.0313	0.0349
x52	-0.0388	0.0214	-1.8078	0.0706	-0.0808	0.0033
x53	0.0160	0.0411	0.3891	0.6972	-0.0645	0.0965
x54	0.0315	0.0270	1.1693	0.2423	-0.0213	0.0844
x55	0.0205	0.0381	0.5365	0.5916	-0.0543	0.0952

=====

CON MUERTOS
 Optimization terminated successfully.
 Current function value: 0.691601
 Iterations 4

Results: Logit

```
=====
Model:                Logit                Pseudo R-squared: -7.779
Dependent Variable: GRAVEDAD                AIC:                33655.4114
Date:                2021-01-28 12:01        BIC:                34100.7054
No. Observations:    24252                Log-Likelihood:    -16773.
Df Model:            54                  LL-Null:          -1910.6
Df Residuals:        24197                LLR p-value:       1.0000
Converged:           1.0000                Scale:           1.0000
No. Iterations:      4.0000
```

	Coef.	Std.Err.	z	P> z	[0.025	0.975]
x1	0.0041	0.0129	0.3167	0.7515	-0.0212	0.0293
x2	0.0010	0.4022	0.0024	0.9980	-0.7873	0.7893
x3	-0.0061	0.4012	-0.0151	0.9880	-0.7924	0.7803
x4	-0.0016	0.0405	-0.0383	0.9694	-0.0809	0.0778
x5	-0.0118	0.0173	-0.6858	0.4929	-0.0457	0.0220
x6	-0.0093	0.0175	-0.5299	0.5962	-0.0437	0.0251
x7	-0.0025	0.0175	-0.1410	0.8879	-0.0368	0.0319
x8	0.0117	0.0173	0.6737	0.5005	-0.0223	0.0457
x9	0.0081	0.0180	0.4527	0.6508	-0.0271	0.0433
x10	-0.0027	0.0174	-0.1553	0.8765	-0.0367	0.0313
x11	-0.0080	0.0171	-0.4691	0.6390	-0.0416	0.0255
x12	-0.0022	0.0179	-0.1220	0.9029	-0.0373	0.0329
x13	-0.0078	0.0178	-0.4377	0.6616	-0.0427	0.0271
x14	-0.0028	0.0176	-0.1604	0.8726	-0.0373	0.0316
x15	-0.0085	0.0175	-0.4836	0.6287	-0.0429	0.0259
x16	-0.0109	0.0160	-0.6789	0.4972	-0.0423	0.0206
x17	0.0015	0.0174	0.0847	0.9325	-0.0326	0.0355
x18	-0.0031	0.0175	-0.1770	0.8595	-0.0374	0.0312
x19	-0.0110	0.0173	-0.6324	0.5271	-0.0449	0.0230
x20	-0.0069	0.0173	-0.3995	0.6895	-0.0409	0.0271
x21	0.0075	0.0177	0.4250	0.6708	-0.0271	0.0422
x22	0.0947	0.0133	7.0946	0.0000	0.0685	0.1208
x23	0.0140	0.0132	1.0595	0.2894	-0.0119	0.0399
x24	0.0040	0.0132	0.3067	0.7591	-0.0217	0.0298
x25	0.0413	0.0124	3.3158	0.0009	0.0169	0.0656
x26	-0.0125	0.0141	-0.8860	0.3756	-0.0403	0.0152
x27	-0.0013	0.0168	-0.0754	0.9399	-0.0342	0.0317
x28	0.0007	0.0152	0.0449	0.9642	-0.0292	0.0306
x29	-0.0018	0.0135	-0.1338	0.8935	-0.0282	0.0246
x30	-0.0064	0.0165	-0.3857	0.6997	-0.0386	0.0259
x31	0.0073	0.0160	0.4581	0.6469	-0.0240	0.0387
x32	-0.0078	0.0210	-0.3703	0.7112	-0.0489	0.0334
x33	0.0011	0.0172	0.0649	0.9483	-0.0326	0.0349
x34	-0.0038	0.0149	-0.2557	0.7982	-0.0329	0.0253
x35	-0.0191	0.0158	-1.2077	0.2272	-0.0502	0.0119
x36	-0.0089	0.0149	-0.5985	0.5495	-0.0381	0.0203
x37	-0.0100	0.0145	-0.6910	0.4896	-0.0385	0.0184
x38	-0.0074	0.0146	-0.5037	0.6145	-0.0360	0.0213
x39	0.0010	0.0244	0.0412	0.9671	-0.0468	0.0489
x40	-0.0085	0.0153	-0.5577	0.5771	-0.0384	0.0214
x41	-0.0132	0.0145	-0.9059	0.3650	-0.0416	0.0153
x42	-0.0091	0.0261	-0.3467	0.7288	-0.0602	0.0421
x43	-0.0010	0.0162	-0.0596	0.9525	-0.0327	0.0308
x44	0.0043	0.0230	0.1871	0.8516	-0.0407	0.0494
x45	-0.0072	0.0205	-0.3485	0.7275	-0.0474	0.0331
x46	-0.0027	0.0194	-0.1409	0.8880	-0.0408	0.0354
x47	0.0021	0.0143	0.1451	0.8847	-0.0259	0.0300
x48	0.0116	0.0147	0.7883	0.4305	-0.0172	0.0405
x49	0.0004	0.0153	0.0251	0.9799	-0.0297	0.0305
x50	-0.0012	0.0173	-0.0672	0.9464	-0.0351	0.0328

SOLO DANOS

Optimization terminated successfully.

Current function value: 0.446000

Iterations 10

Results: Logit

```

=====
Model:                Logit                Pseudo R-squared: 0.288
Dependent Variable:   GRAVEDAD              AIC:                21742.7628
Date:                2021-01-28 12:01       BIC:                22188.0568
No. Observations:    24252                 Log-Likelihood:    -10816.
Df Model:            54                    LL-Null:           -15196.
Df Residuals:        24197                 LLR p-value:       0.0000
Converged:           1.0000                 Scale:            1.0000
No. Iterations:      10.0000
=====

```

	Coef.	Std.Err.	z	P> z	[0.025	0.975]
x1	0.0730	0.0168	4.3507	0.0000	0.0401	0.1059
x2	0.5297	0.5373	0.9859	0.3242	-0.5233	1.5828
x3	0.5161	0.5354	0.9639	0.3351	-0.5333	1.5654
x4	-0.0222	0.0535	-0.4156	0.6777	-0.1270	0.0826
x5	0.0487	0.0225	2.1627	0.0306	0.0046	0.0928
x6	0.0210	0.0226	0.9308	0.3520	-0.0233	0.0653
x7	0.0436	0.0227	1.9152	0.0555	-0.0010	0.0882
x8	0.0292	0.0223	1.3081	0.1908	-0.0146	0.0730
x9	0.0476	0.0234	2.0292	0.0424	0.0016	0.0935
x10	0.0369	0.0226	1.6360	0.1018	-0.0073	0.0811
x11	0.0160	0.0221	0.7254	0.4682	-0.0272	0.0592
x12	0.0566	0.0233	2.4256	0.0153	0.0109	0.1024
x13	0.0576	0.0233	2.4719	0.0134	0.0119	0.1033
x14	0.0233	0.0227	1.0284	0.3038	-0.0211	0.0678
x15	0.0271	0.0228	1.1857	0.2357	-0.0177	0.0719
x16	-0.0287	0.0206	-1.3927	0.1637	-0.0691	0.0117
x17	-0.0172	0.0228	-0.7542	0.4507	-0.0618	0.0274
x18	-0.0189	0.0228	-0.8256	0.4090	-0.0636	0.0259
x19	0.0033	0.0228	0.1450	0.8847	-0.0414	0.0480
x20	0.0361	0.0229	1.5781	0.1145	-0.0087	0.0810
x21	0.0288	0.0234	1.2316	0.2181	-0.0171	0.0747
x22	-2.6804	0.2971	-9.0226	0.0000	-3.2627	-2.0981
x23	-2.5068	0.6388	-3.9241	0.0001	-3.7588	-1.2547
x24	-0.2509	0.0254	-9.8673	0.0000	-0.3007	-0.2010
x25	-0.3086	0.0160	-19.2330	0.0000	-0.3400	-0.2771
x26	-0.0190	0.0169	-1.1209	0.2623	-0.0521	0.0142
x27	0.1724	0.0229	7.5399	0.0000	0.1276	0.2172
x28	-0.0167	0.0184	-0.9094	0.3631	-0.0528	0.0193
x29	0.0934	0.0232	4.0221	0.0001	0.0479	0.1389
x30	0.2540	0.0241	10.5348	0.0000	0.2067	0.3012
x31	-0.0065	0.0201	-0.3251	0.7451	-0.0460	0.0329
x32	0.1020	0.0270	3.7851	0.0002	0.0492	0.1549
x33	0.1525	0.0227	6.7231	0.0000	0.1080	0.1969
x34	0.0894	0.0196	4.5679	0.0000	0.0510	0.1277
x35	0.0396	0.0193	2.0527	0.0401	0.0018	0.0775
x36	-0.0213	0.0184	-1.1541	0.2485	-0.0574	0.0149
x37	-0.0497	0.0175	-2.8415	0.0045	-0.0840	-0.0154
x38	0.0686	0.0196	3.4953	0.0005	0.0301	0.1071
x39	0.0806	0.0316	2.5512	0.0107	0.0187	0.1426
x40	0.1305	0.0201	6.4889	0.0000	0.0911	0.1699
x41	-0.0378	0.0172	-2.2012	0.0277	-0.0714	-0.0041
x42	0.2455	0.0349	7.0295	0.0000	0.1771	0.3140
x43	0.0186	0.0210	0.8864	0.3754	-0.0225	0.0597
x44	0.0039	0.0306	0.1275	0.8986	-0.0562	0.0640
x45	-0.1246	0.0270	-4.6214	0.0000	-0.1774	-0.0717
x46	-0.0474	0.0254	-1.8650	0.0622	-0.0972	0.0024
x47	0.0276	0.0221	1.2501	0.2113	-0.0157	0.0708
x48	0.0166	0.0205	0.8071	0.4196	-0.0236	0.0567
x49	-0.0096	0.0197	-0.4888	0.6250	-0.0482	0.0289
x50	-0.0129	0.0227	-0.5703	0.5685	-0.0575	0.0316

```
In [20]: a = np.array(probas_logit)
y_pred = a.argmax(axis=0)
y_pred = [pd.get_dummies(y_train).columns[a] for a in y_pred]
```

```
In [21]: cm = confusion_matrix(y_test, y_pred)
pd.DataFrame(cm, columns=pd.get_dummies(y_train).columns, index = pd.get_dummies(y_train).columns)
```

Out[21]:

	CON HERIDOS	CON MUERTOS	SOLO DANOS
CON HERIDOS	1387	0	1945
CON MUERTOS	86	0	73
SOLO DANOS	21	0	6883

```
In [22]: true_values = np.trace(cm)
false_values = np.sum(cm)-true_values
test_accuracy = true_values / (true_values+false_values)
test_accuracy
```

Out[22]: 0.7955747955747956

Diciembre 2020

9. Bibliografía

10 datos sobre la seguridad vial en el mundo. Organización Mundial de la Salud. (2017). <https://www.who.int/features/factfiles/roadsafety/es/>.

Anuario de Siniestralidad Vial de Bogotá. Secretaría Distrital de Movilidad. (2018) (1a ed.).

Anuario de Siniestralidad Vial de Bogotá. Secretaría Distrital de Movilidad. (2019) (1a ed.).

Anuario Nacional de Siniestralidad Vial. Agencia Nacional de Seguridad Vial (2010) (1ª ed.)

Arias, W., Colucci, B., (2006). Road Safety Audit., 19(3), p.28

Chang, L.-Y., & Wang, H.-W. (2006). Analysis of traffic injury severity: An application of non-parametric classification tree techniques. Accident Analysis & Prevention, 38(5), 1019–1027. <https://doi.org/10.1016/j.aap.2006.04.009>

Giraldo Salazar, J. (2015). Auditoria de la Seguridad Vial para cuantificar el riesgo en la vía de los usuarios, en los barrios Pablo Sexto, Galerías y Nicolás de Federman. Repository.usta.edu.co. Retrieved 14 June 2020, from <https://repository.usta.edu.co/bitstream/handle/11634/704/Auditoria%20de%20la%20Seguridad%20Vial%20para%20cuantificar%20el%20riesgo%20en%20la%20via%20de%20los%20usuario.pdf?sequence=1&jsAllowed=y>.

Instituto de Desarrollo Urbano (2019). Infraestructura de Datos Espaciales de Bogotá. Retrieved 10 December 2020, from <https://www.ideca.gov.co/recursos/mapas/estado-superficial-bogota-dc>

Jimenez Florez, A. (2021). Repositorio.uniandes.edu.co. Retrieved 28 April 2020, from <https://repositorio.uniandes.edu.co/bitstream/handle/1992/7827/u703307.pdf?sequence=1>.

Li, Y., Liu, C., & Ding, L. (2013). *Impact of pavement conditions on crash severity*. *Accident Analysis & Prevention*, 59, 399-406. <https://doi.org/10.1016/j.aap.2013.06.028>

Li, Y., Ma, D., Zhu, M., Zeng, Z., & Wang, Y. (2018). *Identification of significant factors in fatal-injury highway crashes using genetic algorithm and neural network*. *Accident Analysis & Prevention*, 111, 354-363. <https://doi.org/10.1016/j.aap.2017.11.028>

Plan Nacional de Seguridad Vial Colombia 2011 – 2021. Agencia Nacional de Seguridad Vial (2011) (1ª ed.)

Quevedo, F., Pérez, M., & Lara, Y. (2021). *Determinación de los componentes entrópicos de la accidentalidad: el trinomio vehículo/usuario/camino en la metrópoli de Guadalajara, México*. Dialnet. Retrieved 12 march 2020, from <https://dialnet.unirioja.es/servlet/articulo?codigo=6772584>.

Revista Ingeniería. (2011). Retrieved September 19, 2020, from Udistrital.edu.co website: <https://revistas.udistrital.edu.co/index.php/REDES/article/view/12495/13099>

Xie, Y., Lord, D., & Zhang, Y. (2007). *Predicting motor vehicle collisions using Bayesian neural network models: An empirical analysis*. *Accident Analysis & Prevention*, 39(5), 922-933. <https://doi.org/10.1016/j.aap.2006.12.014>

Zeng, Q., & Huang, H. (2014). *A stable and optimized neural network model for crash injury severity prediction*. *Accident Analysis & Prevention*, 73, 351-358. <https://doi.org/10.1016/j.aap.2014.09.006>